

INSTITUT UNIVERSITAIRE SAINT JEAN
SAINT JEAN INGENIEUR
B.P 749 - YAOUNDE
CAMEROUN



SAINT JEAN INSTITUT UNIVERSITY
SAINT JEAN ENGINEER
B.P. 749 – YAOUNDE
CAMEROON

THEME :
**RAPPORT D'ANALYSE SUR LES FACTEURS INFLUENCANT
LE DESIR D'AVOIR D'AUTRES ENFANTS**

Rédigé et présenté par :

KAYE SIAGAM Grace Pauline Lara

Etudiante en Master 1 Informatique et Système d'information – Option Data Science

SOUS L'ENCADREMENT : de Pr. NGUEFACK

ANNEE ACADEMIQUE 2025-2026

Données : CMIR71FL.SAV — EDSC-V 2018 | Chapitre 6 : Préférences en matière de
fécondité

Résumé

Introduction. Avec un indice synthétique de fécondité de 5,4 enfants par femme (EDSC-V 2018), le Cameroun demeure un pays à forte fécondité. Le désir d'avoir un autre enfant, déterminant proximal de la fécondité, reste difficile à modéliser car les effets conjoints des facteurs socioéconomiques se prêtent mal aux seules approches statistiques classiques. Cette étude identifie et quantifie les déterminants de ce désir chez les femmes de 15 à 49 ans, en combinant analyse statistique classique et Machine Learning interprétable.

Méthodes. Les données proviennent du fichier individuel femme de l'EDSC-V (CMIR71FL), réduit à 13 527 femmes après nettoyage. La cible (v602) est binarisée (désire vs ne désire pas). Dix-neuf variables explicatives ont été retenues après un encodage conforme aux conventions DHS. La Partie A mobilise statistiques descriptives, tests du Chi² (V de Cramér), Mann-Whitney et régression logistique binaire (OR, IC 95 %), avec diagnostics VIF, Hosmer-Lemeshow, calibration et Brier. La Partie B traite le déséquilibre (94,5 %/5,5 %) par SMOTE sur l'entraînement, puis compare six algorithmes (régression logistique, Random Forest, arbre de décision, SVM-RBF, KNN, XGBoost) avec validation croisée 5-fold, courbes d'apprentissage et interprétabilité par SHAP.

Résultats. La prévalence du désir atteint 94,5 %, très supérieure aux 64,95 % d'Afrique subsaharienne. L'âge est le prédicteur le plus robuste (OR = 0,859 ; $p < 0,001$) et le milieu rural est associé à un désir plus faible après ajustement (OR = 0,703). À l'inverse, la parité, la contraception et le statut de femme mariée s'accompagnent d'un désir accru. Le SVM calibré (noyau RBF) est retenu (AUC CV-5 = 0,969 ; AUC test = 0,795 ; Brier = 0,074 ; spécificité 45,0 %), la régression logistique offrant la meilleure généralisation (AUC test = 0,820). L'analyse SHAP confirme la prééminence de l'âge. Le modèle SVM est déployé dans l'application HEARTH accessible à l'adresse <https://hearth-edsc-prediction-d-avoir-des.onrender.com> et le code sur github via le lien <https://github.com/Kayela2/Prediction-d-avoir-des-enfants/tree/main/EDS-Cameroon>

Discussion. Dans un contexte de désir quasi universel, l'âge et le milieu de résidence structurent l'essentiel de la variabilité. Ces modèles éclairent les profils de risque populationnels et fondent des recommandations ciblées de santé reproductive. Le modèle est opérationnalisé dans l'application web HEARTH.

Mots-clés : fécondité ; désir d'enfant ; EDSC-V 2018 ; Cameroun ; régression logistique ; Odds Ratio ; Machine Learning ; SMOTE ; SVM ; SHAP ; santé reproductive.

Table des matières

Résumé	3
Table des matières	4
Introduction	6
I. Étude de l'existant et problématique	6
1.1 Présentation du thème (Chapitre 6 – EDSC-V).....	6
1.2 Revue de littérature et critique de l'existant	6
Revue de littérature.....	6
Critique de l'existant.....	6
1.3 Problématique.....	7
1.4 Hypothèses de recherche	7
II. Objectifs de l'étude	7
2.1 Objectif général	7
2.2 Objectifs spécifiques	7
III. Matériaux et Méthodes	8
3.1 Source et description des données.....	8
3.2 Population cible et critères d'inclusion/exclusion.....	8
3.3 Opérationnalisation des variables.....	8
Variable dépendante	8
Variables explicatives — encodage corrigé (19 variables)	8
3.4 Méthodes d'analyse.....	9
Partie A — Analyse statistique classique.....	9
Partie B — Machine Learning.....	9
IV. Présentation et analyse des résultats.....	10
4.1 Statistiques descriptives.....	10
4.2 Tests d'association bivariée — χ^2 et Mann-Whitney	13
4.3 Régression logistique binaire — résultats et interprétation.....	15
4.3.1 Résultats du modèle (19 variables).....	15
4.3.2 Interprétation des Odds Ratios et test des hypothèses	18
4.4 Résultats du Machine Learning — six modèles avec SMOTE	19
4.4.1 Traitement du déséquilibre des classes (SMOTE).....	19

4.4.2 Comparaison des six modèles	20
4.4.3 Analyse du surapprentissage et courbes d'apprentissage.....	20
4.4.4 Stabilité et calibration.....	21
4.4.5 Sélection et justification du meilleur modèle	23
4.5 Interprétabilité des modèles — SHAP et importance par permutation	24
V. Discussion.....	27
5.1 Principaux enseignements	27
5.2 Apport du Machine Learning et de SMOTE	27
5.3 Contribution originale	28
5.4 Limites.....	28
VI. Conclusion et recommandations	28
6.1 Synthèse.....	28
6.2 Recommandations	28
6.3 Perspectives	29
VII. Application HEARTH	29
7.1 Présentation	29
7.2 Fonctionnement.....	29
Références bibliographiques	29
Annexe 1 — Vérification de la multicollinéarité (VIF)	30

Introduction

La fécondité constitue l'un des déterminants fondamentaux de la dynamique démographique des pays en développement. Le Cameroun, avec un indice synthétique de fécondité (ISF) estimé à 5,4 enfants par femme selon l'EDSC-V 2018 (INS & ICF, 2020), se situe parmi les pays à forte fécondité de la sous-région. La compréhension des préférences reproductives — et en particulier du désir d'avoir un autre enfant — est essentielle pour orienter les politiques de planification familiale et anticiper l'évolution de la population.

Le Chapitre 6 du rapport national de l'EDSC-V, consacré aux « Préférences en matière de fécondité », fournit des données riches sur les intentions reproductives des femmes en âge de procréer (15–49 ans). À partir de la variable v602 (« désir d'avoir d'autres enfants »), la présente étude analyse un échantillon final de 13 527 femmes, dont 12 782 (94,5 %) déclarent désirer un autre enfant et 745 (5,5 %) ne le désirant pas. Ce déséquilibre marqué constitue à la fois une caractéristique démographique notable et un défi méthodologique central, que nous traitons en combinant régression logistique classique et techniques de Machine Learning interprétable (SMOTE, comparaison multi-algorithmes, SHAP).

I. Étude de l'existant et problématique

1.1 Présentation du thème (Chapitre 6 – EDSC-V)

Le projet se concentre sur le Chapitre 6 du rapport national de l'EDSC-V, qui traite du désir d'avoir un autre enfant (variable v602), du nombre idéal d'enfants et de la planification des naissances passées. Ces indicateurs renseignent sur l'écart entre fécondité désirée et fécondité observée, et sur les besoins non satisfaits en matière de contraception.

1.2 Revue de littérature et critique de l'existant

Revue de littérature

Ahinkorah et al. (2020) ont analysé le désir d'enfant chez 232 784 femmes de 32 pays africains et montré que la prévalence globale était de 64,95 %, avec l'âge, le niveau d'instruction, la parité, l'utilisation de contraceptifs et le milieu de résidence comme principaux prédicteurs. Muluneh & Moyehodie (2021) ont montré que l'absence d'éducation augmente significativement le désir d'enfant en Éthiopie (AOR = 1,85). Church et al. (2023), dans une revue systématique de 258 études, identifient 31 déterminants du désir de fécondité élevé en Afrique subsaharienne. Plus récemment, des travaux exploratoires (Frontiers in Digital Health, 2024 ; Seidu et al., 2025) appliquent des algorithmes de Machine Learning à la prédiction des préférences de fécondité, ouvrant la voie à une démographie computationnelle.

Critique de l'existant

Les études existantes sur la fécondité en Afrique subsaharienne se limitent généralement à des régressions logistiques univariées ou multiniveaux (Ahinkorah et al., 2020 ; Muluneh & Moyehodie, 2021), sans traitement du déséquilibre des classes ni comparaison multi-algorithmique. Au Cameroun spécifiquement, aucune analyse utilisant les données EDSC-V 2018 (v602) n'a, à ce jour, combiné régression logistique binaire, Machine Learning multi-algorithmes

avec SMOTE, et interprétabilité par SHAP. Le présent travail comble cette lacune en s'inspirant de la démarche méthodologique de Dai et al. (2026, PLOS One), qui appliquent une approche analogue à la prédiction de comorbidités.

1.3 Problématique

Face à une fécondité encore élevée (ISF = 5,4) et à des besoins non satisfaits en planification familiale estimés à environ 23 %, le Cameroun présente un écart persistant entre fécondité désirée ($\approx 4,3$ enfants) et nombre idéal déclaré ($\approx 6,0$ enfants). Comprendre ce qui sous-tend le désir d'enfant supplémentaire est donc une condition préalable à toute action publique efficace.

Question de recherche : Quels sont les facteurs socioéconomiques et démographiques qui influencent significativement le désir d'avoir un autre enfant chez les femmes camerounaises (15–49 ans), à partir des données de l'EDSC-V 2018 ?

1.4 Hypothèses de recherche

- H1 : L'âge de la femme est négativement associé au désir d'avoir un autre enfant.
- H2 : Le niveau d'instruction est négativement associé au désir de fécondité.
- H3 : Le nombre d'enfants vivants est négativement associé au désir d'enfant supplémentaire.
- H4 : L'utilisation d'une méthode contraceptive est négativement associée au désir d'enfant.
- H5 : Le milieu de résidence rural est positivement associé au désir d'avoir un autre enfant.

II. Objectifs de l'étude

2.1 Objectif général

Identifier et quantifier les déterminants socioéconomiques et démographiques du désir d'avoir un autre enfant au Cameroun à partir des données de l'EDSC-V 2018, en combinant analyse statistique classique et Machine Learning interprétable.

2.2 Objectifs spécifiques

- Décrire la distribution du désir d'enfant supplémentaire selon les caractéristiques socioéconomiques et démographiques des femmes ;
- Tester l'association statistique entre chaque variable explicative et la variable dépendante (Chi², V de Cramér, Mann-Whitney) ;
- Construire un modèle de régression logistique binaire et interpréter les Odds Ratios avec leurs intervalles de confiance à 95 %, en contrôlant la multicollinéarité (VIF) et l'adéquation (Hosmer-Lemeshow, calibration, Brier) ;
- Traiter le déséquilibre des classes par SMOTE et comparer six algorithmes de Machine Learning avec validation croisée 5-fold, courbes d'apprentissage et analyse du surapprentissage ;
- Interpréter le modèle par SHAP et importance par permutation, puis sélectionner et déployer le meilleur modèle ;
- Formuler des recommandations de politique publique en santé reproductive.

III. Matériaux et Méthodes

3.1 Source et description des données

Les données proviennent de la cinquième Enquête Démographique et de Santé du Cameroun (EDSC-V), conduite entre juillet 2018 et février 2019 par l'Institut National de la Statistique (INS) en partenariat avec ICF International (programme DHS/USAID). Le fichier analysé est le recode individuel femme CMIR71FL.SAV. Après chargement, le fichier brut comporte 14 677 femmes de 15 à 49 ans ; après exclusion des valeurs manquantes sur v602 et des observations non classifiables, l'effectif analytique final est de 13 527 femmes.

3.2 Population cible et critères d'inclusion/exclusion

Tableau 1 — Critères d'inclusion et d'exclusion de l'échantillon d'analyse

Critères d'inclusion	Critères d'exclusion
Femmes âgées de 15 à 49 ans	Valeur manquante sur v602 (variable cible)
Résidentes habituelles des ménages enquêtés	Réponses « ne sait pas » ou « autre » non classifiables
Ayant répondu à la question v602	Observations aberrantes sur l'âge (< 15 ou > 49)

3.3 Opérationnalisation des variables

Variable dépendante

La variable cible est construite à partir de v602 (« Desire for more children »), binarisée conformément aux conventions DHS :

- Valeur 1 — Désire un autre enfant : modalités « veut bientôt », « veut plus tard » et « indécis(e) » → 12 782 femmes (94,5 %) ;
- Valeur 0 — Ne désire pas : modalités « ne veut plus », « stérilisée », « partenaire stérilisé », « déclarée stérile » → 745 femmes (5,5 %).

Variables explicatives — encodage corrigé (19 variables)

Par rapport aux premières versions de l'analyse, l'encodage a été corrigé et étendu pour respecter rigoureusement la nature des variables DHS : (i) la contraception (v313) est éclatée en deux indicatrices (traditionnelle / moderne, référence = aucune méthode) au lieu d'une simple binaire ; (ii) le statut matrimonial (v501) est éclaté en cinq indicatrices (référence = jamais mariée) au lieu d'une variable ordinale 0–5 ; (iii) la religion (v130) est éclatée en quatre indicatrices (référence = catholique) ; (iv) le milieu de résidence est recodé 0 = urbain (référence) / 1 = rural ; (v) le nombre d'enfants décédés est ajouté pour capter l'effet de remplacement. Le modèle compte ainsi 19 régresseurs.

Tableau 2 — Description des variables explicatives et de la variable cible — EDSC-V Cameroun 2018

Code DHS	Variable	Type	Modalités / Distribution
v012	Âge	Quantitative	15–49 ans · Moy. = 27,80 · Méd. = 26 · σ = 9,44
v106	Niveau d'instruction	Ordinale	Aucun 17,5 % · Primaire 28,0 % · Secondaire 47,3 % ·

			Supérieur 7,2 %
v218	Nb enfants vivants	Quantitative	0–13 · Moy. = 2,25 · Méd. = 2 · σ = 2,30
v206/207	Nb enfants décédés	Quantitative	0–9 · Moy. = 0,27 (effet de remplacement)
v313	Contraception	2 indicatrices	Aucune 79,8 % (réf.) · Traditionnelle 3,2 % · Moderne 17,0 %
v501	Statut matrimonial	5 indicatrices	Jamais mariée 35,9 % (réf.) · Mariée 40,8 % · Union libre 14,4 % · Veuve 2,7 % · Divorcée 1,5 % · Séparée 4,8 %
v025	Milieu de résidence	Binaire	Urbain 54,3 % (réf.) · Rural 45,7 %
v190	Quintile de richesse	Ordinale	Du plus pauvre (13,5 %) au plus riche (22,2 %)
v714	Emploi (travail)	Binaire	En activité 60,6 % · Sans emploi 39,4 %
v024	Région septentrionale	Binaire	1 = Adamaoua/Nord/Extrême-Nord · 0 = autre région
v130	Religion	4 indicatrices	Catholique 37,4 % (réf.) · Protestante 28,7 % · Autres chrét. 7,9 % · Musulmane 22,6 % · Autres 1,7 %
v602	Désir d'enfant (CIBLE)	Binaire	Désire 94,5 % (n = 12 782) · Ne désire pas 5,5 % (n = 745)

3.4 Méthodes d'analyse

Partie A — Analyse statistique classique

L'analyse statistique comprend : (i) des statistiques descriptives univariées ; (ii) des tests du Chi² de Pearson avec calcul du V de Cramér pour les variables catégorielles ; (iii) des tests de Mann-Whitney pour les variables continues ; (iv) une matrice de corrélation. La régression logistique binaire est estimée par maximum de vraisemblance (statsmodels). Les résultats sont exprimés en Odds Ratios (OR = $\exp(\beta)$) avec IC 95 %. La qualité d'ajustement est évaluée par les pseudo-R² (McFadden, Nagelkerke), l'AIC, le test de Hosmer-Lemeshow, la courbe de calibration et le score de Brier. La multicollinéarité est vérifiée par le facteur d'inflation de la variance (VIF, seuil critique = 10). Le modèle s'écrit :

$$\text{logit}[P(Y = 1)] = \beta_0 + \sum \beta_j \cdot X_j \quad (j = 1 \dots 19)$$

Partie B — Machine Learning

La partie ML comprend : (1) la préparation et le nettoyage des données ; (2) le traitement du déséquilibre des classes par SMOTE (Synthetic Minority Over-sampling Technique) appliqué uniquement sur les données d'entraînement ; (3) la comparaison de six modèles ; (4) la validation croisée 5-fold ; (5) l'analyse du surapprentissage via les courbes d'apprentissage et l'écart AUC train/test ; (6) l'évaluation de la calibration (courbes de fiabilité, score de Brier) ; (7) l'interprétabilité (SHAP, importance par permutation). Les six modèles sont :

- Régression Logistique (régularisation L2, pondération des classes) ;
- Random Forest (100 arbres) ;
- Arbre de Décision (profondeur maximale = 5) ;
- SVM — Support Vector Machine (noyau RBF, données normalisées, sortie calibrée) ;
- KNN — K plus proches voisins (k = 5, données normalisées) ;
- XGBoost — Gradient Boosting (100 estimateurs).

Le partage est de 80 % / 20 % stratifié. Les métriques retenues sont : Accuracy, ROC-AUC (métrique principale, non affectée par le déséquilibre), F1-score, sensibilité, spécificité, AUC en validation croisée 5-fold, écart de surapprentissage et score de Brier. Tous les traitements sont réalisés sous Python (pandas, numpy, scikit-learn, imbalanced-learn, xgboost, statsmodels, shap).

IV. Présentation et analyse des résultats

4.1 Statistiques descriptives

L'effectif analytique final est de 13 527 femmes en âge de procréer (15–49 ans). Parmi celles-ci, 12 782 femmes (94,5 %) déclarent désirer un autre enfant contre seulement 745 (5,5 %) ne le désirant pas. Cette forte prévalence, très supérieure aux 64,95 % observés en moyenne en Afrique subsaharienne (Ahinkorah et al., 2020), est caractéristique du contexte démographique camerounais et constitue le fil conducteur de l'interprétation.

Tableau 3 — Statistiques descriptives des variables numériques — EDSC-V 2018 (n = 13 527)

Variable	N	Moy.	Méd.	σ	Min.	Q3	Max.
Âge (années)	13 527	27,80	26,00	9,44	15	35	49
Nb enfants vivants	13 527	2,25	2,00	2,30	0	4	13
Nb enfants total	13 527	2,51	2,00	2,62	0	4	16
Nb enfants décédés	13 527	0,27	0,00	—	0	0	9

S'agissant des variables catégorielles : 54,3 % des femmes résident en milieu urbain et 45,7 % en milieu rural. La tranche 15–19 ans est la plus représentée (24,8 %). 17,5 % des femmes n'ont aucun niveau d'instruction tandis que 47,3 % ont atteint le secondaire. 60,6 % exercent une activité professionnelle. Sur le plan religieux, les catholiques (37,4 %) et protestantes (28,7 %) dominent, devant les musulmanes (22,6 %). En matière de contraception, 20,2 % des femmes utilisent une méthode (17,0 % moderne, 3,2 % traditionnelle).




Figure 1 — Distribution de la variable cible — 12 782 femmes (94,5 %) désirent un autre enfant vs 745 (5,5 %) ne le désirant pas




Figure 2 — Distribution des variables continues selon le désir — les femmes ne désirant pas d'enfant sont nettement plus âgées (moy. = 38,4 vs 27,2 ans) et ont davantage d'enfants




Figure 3 — Proportion de femmes désirant un autre enfant par tranche d'âge — de 98,4 % (15–19 ans) à 67,4 % (45–49 ans)




Figure 4 — Proportion désirant un autre enfant par niveau d'instruction — légère tendance croissante (Aucun 92,0 % → Supérieur 97,4 %)




Figure 5 — Analyses croisées — désir par âge et milieu de résidence (gauche) et par quintile de richesse et instruction (droite)

4.2 Tests d'association bivariable — Chi² et Mann-Whitney

Huit variables sur dix testées sont significativement associées au désir d'enfant en analyse bivariable (Tableau 4). La tranche d'âge présente de loin l'association la plus forte (V de Cramér = 0,345), suivie du statut matrimonial (V = 0,145, association modérée). La région septentrionale (p = 0,545) et la religion musulmane (p = 0,590) ne sont pas significativement associées au niveau bivariable.

Tableau 4 — Résultats des tests du Chi² — *** p < 0,001 · NS = non significatif (n = 13 527)

Variable explicative	Chi ²	ddl	p-value	V Cramér	Force	Sig.
Tranche d'âge	1 605,85	6	< 0,001	0,345	Forte	***
Statut matrimonial	282,96	5	< 0,001	0,145	Modérée	***
Niveau d'instruction	80,45	3	< 0,001	0,077	Faible	***
Emploi (travail)	69,46	1	< 0,001	0,072	Faible	***
Utilisation contraceptif	50,00	1	< 0,001	0,061	Faible	***
Quintile de richesse	31,56	4	< 0,001	0,048	Faible	***
Milieu de résidence	21,24	1	< 0,001	0,040	Faible	***
Religion (générale)	4,10	5	0,535	0,017	Négligeable	NS
Région septentrionale	0,37	1	0,545	0,005	Négligeable	NS
Religion musulmane	0,29	1	0,590	0,005	Négligeable	NS

Tableau 5 — Tests de Mann-Whitney — comparaison des moyennes selon le désir d'enfant

Variable continue	Moy. (Désire)	Moy. (Ne désire pas)	p-value	Sig.
Âge (années)	27,19	38,38	< 0,001	***
Nb enfants vivants	2,19	3,16	< 0,001	***
Nb enfants total	2,44	3,70	< 0,001	***




Figure 6 — Désir d'enfant selon le nombre d'enfants vivants — de 96,5 % (0 enfant) à 86,3 % (8 enfants)




Figure 7 — Désir selon le milieu de résidence (Rural 93,5 % vs Urbain 95,3 %) et la contraception (non-utilisatrices 93,8 % vs utilisatrices 97,3 %)




Figure 8 — Matrice de corrélation des variables — corrélation forte âge/nombre d'enfants ($r = 0,68$) et résidence/richesse ($r = -0,67$)

4.3 Régression logistique binaire — résultats et interprétation

4.3.1 Résultats du modèle (19 variables)

Le modèle logistique multivarié, ajusté sur les dix-neuf régresseurs, affiche un pseudo- R^2 de Nagelkerke de 23,4 %, un AIC de 4 660,87 et une AUC de 0,809. Le test de Hosmer-Lemeshow ($\chi^2(8) = 47,09$; $p < 0,001$) signale un ajustement local perfectible ; toutefois, avec $n = 13\,527$, ce test est extrêmement sensible à la taille de l'échantillon, et la courbe de calibration accompagnée d'un score de Brier très faible (0,0445) atteste d'une qualité prédictive globale satisfaisante (Figure 10).

Tableau 6 — Régression logistique — Odds Ratios ajustés avec IC 95 % (19 variables, encodage corrigé).
Réf. : contraception = aucune ; matrimonial = jamais mariée ; religion = catholique ; résidence = urbain

Variable	β	OR ajusté	IC inf.	IC sup.	p-value	Sig.
Constante	6.779	878.726	522.550	1477.677	< 0,001	***
Âge	-0.152	0.859	0.850	0.869	< 0,001	***

Niveau d'instruction	0.144	1.154	1.017	1.311	0,027	*
Nb enfants vivants	0.183	1.201	1.153	1.250	< 0,001	***
Nb enfants décédés	0.025	1.025	0.942	1.115	0,564	NS
Contraceptif traditionnel	1.964	7.127	2.620	19.389	< 0,001	***
Contraceptif moderne	0.390	1.476	1.134	1.922	0,004	**
Mariée (vs jamais mariée)	0.366	1.443	1.112	1.871	0,006	**
Union libre (vs jamais mariée)	0.050	1.051	0.781	1.415	0,742	NS
Veuve (vs jamais mariée)	-0.090	0.914	0.630	1.326	0,637	NS
Divorcée (vs jamais mariée)	-0.083	0.920	0.549	1.542	0,752	NS
Séparée (vs jamais mariée)	0.267	1.307	0.897	1.904	0,164	NS
Résidence rurale (vs urbaine)	-0.352	0.703	0.566	0.875	0,002	**
Quintile de richesse	0.046	1.047	0.954	1.149	0,330	NS
Emploi (travail)	0.079	1.082	0.892	1.312	0,425	NS
Région septentrionale	0.060	1.062	0.871	1.295	0,550	NS
Protestante (vs Catholique)	0.041	1.042	0.857	1.267	0,680	NS
Autres chrétiennes (vs Catholique)	-0.032	0.968	0.710	1.321	0,839	NS
Musulmane (vs Catholique)	0.015	1.015	0.795	1.296	0,905	NS
Autres religions (vs Catholique)	-0.048	0.954	0.560	1.622	0,861	NS

Pseudo-R² Nagelkerke = 23,4 % · AIC = 4 660,87 · AUC = 0,809 · Brier = 0,0445 · Hosmer-Lemeshow $\chi^2(8) = 47,09$ ($p < 0,001$) · N = 13 527.

Figure 9 — Forest plot des Odds Ratios ajustés (modèle corrigé, 19 variables)
Rouge = significatif ($p < 0,05$) · Gris = non significatif · Trait pointillé = OR = 1




Figure 9 — Forest plot des Odds Ratios ajustés (19 variables) — rouge = significatif ($p < 0,05$), gris = non significatif, trait pointillé = OR = 1

Validation du modèle de Régression Logistique EDSC Cameroun 2018 (encodage corrigé)




Figure 10 — Validation du modèle logistique — (A1) courbe ROC ($AUC = 0,809$) ; (A2) calibration ($Brier = 0,0445$) ; (A3) résidus de Pearson ; (A4) sensibilité/spécificité selon le seuil (seuil optimal = 0,95)

4.3.2 Interprétation des Odds Ratios et test des hypothèses

Cinq variables ressortent significatives. Les résultats, dans ce contexte de désir quasi universel, conduisent à valider H1 et à infirmer H2, H3, H4 et H5.

- H1 — Âge (VALIDÉE, ***) : OR = 0,859 (IC 95 % : 0,850–0,869 ; $p < 0,001$). Chaque année supplémentaire réduit de 14,1 % la cote de désirer un enfant. C'est le prédicteur le plus robuste de l'étude.
- H2 — Instruction (INFIRMÉE, *) : OR = 1,154 (IC 95 % : 1,017–1,311 ; $p = 0,027$). Contrairement à l'hypothèse, les femmes plus instruites désirent légèrement plus un enfant — effet lié à la prévalence quasi universelle du désir.
- H3 — Nb d'enfants vivants (INFIRMÉE, ***) : OR = 1,201 (IC 95 % : 1,153–1,250 ; $p < 0,001$). L'effet classique de parité est masqué par la forte prévalence : même avec huit enfants, 86,3 % des femmes désirent encore un enfant.
- H4 — Contraception (INFIRMÉE, *** / **): la contraception traditionnelle (OR = 7,13 ; $p < 0,001$) et moderne (OR = 1,48 ; $p = 0,004$) s'accompagnent d'un désir accru. En Afrique subsaharienne, la contraception sert surtout à espacer les naissances et non à y mettre fin : les utilisatrices restent très majoritairement désirantes.

- H5 — Milieu de résidence (INFIRMÉE, **) : OR = 0,703 pour le milieu rural (IC 95 % : 0,566–0,875 ; p = 0,002). Une fois les autres facteurs contrôlés, les femmes rurales désirent moins un enfant supplémentaire que les urbaines — résultat cohérent avec les proportions brutes (rural 93,5 % vs urbain 95,3 %) et qui infirme l'hypothèse d'un effet rural positif.

Le statut de femme mariée est par ailleurs associé à un désir accru (OR = 1,44 ; p = 0,006). Les autres variables — quintile de richesse, emploi, région septentrionale et catégories religieuses — ne sont pas significatives dans le modèle multivarié.

Tableau 7 — Synthèse du test des hypothèses de recherche (modèle logistique corrigé)

Hypothèse	Variable	OR	p-value	Statut
H1	Âge (négatif)	0,859	< 0,001	✓ Validée
H2	Instruction (négatif)	1,154	0,027	✗ Infirmée
H3	Nb enfants vivants (négatif)	1,201	< 0,001	✗ Infirmée
H4	Contraception (négatif)	1,48 / 7,13	< 0,01	✗ Infirmée
H5	Résidence rurale (positif)	0,703	0,002	✗ Infirmée

Note de multicolinéarité : l'âge (VIF = 19,43) et le quintile de richesse (VIF = 11,98) dépassent le seuil critique de 10 (Annexe 1), en raison de leurs corrélations avec la parité et le milieu de résidence. Cette multicolinéarité ne dégrade pas la qualité prédictive mais rend délicate l'isolation des effets propres de ces deux variables.

4.4 Résultats du Machine Learning — six modèles avec SMOTE

4.4.1 Traitement du déséquilibre des classes (SMOTE)

Le jeu de données présente un fort déséquilibre (94,5 % vs 5,5 %). SMOTE a été appliqué uniquement sur les données d'entraînement (10 821 → 20 450 observations, soit 9 629 observations synthétiques de la classe minoritaire) afin d'équilibrer les classes à 50/50. Les données de test (n = 2 706) sont restées strictement inchangées, garantissant une évaluation non biaisée.




Figure 11 — Impact de SMOTE — distribution avant (94,5 % / 5,5 %) et après équilibrage (50 % / 50 %, sur l'entraînement uniquement)

4.4.2 Comparaison des six modèles

Le Tableau 8 présente les performances des six modèles, évaluées sur les données de test originales. L'AUC-ROC est la métrique principale car non affectée par le déséquilibre des classes.

Tableau 8 — Comparaison des six modèles ML après SMOTE — partage 80/20 stratifié · AUC CV-5 = AUC moyen en validation croisée 5-fold · Gap = AUC train – AUC test

Modèle	Acc.	AUC test	F1	Sensib.	Spécif.	AUC CV-5	Gap	Brier	Diagnostic
Rég. Logistique	78.6 %	0.820	0.874	78.7 %	76.5 %	0.818	-0.001	0.162	Bon modèle
SVM (RBF) ★ RETENU	91.6 %	0.795	0.955	94.3 %	45.0 %	0.969	0.181	0.074	Léger overfitting
Arbre Décision	85.1 %	0.744	0.917	86.9 %	54.4 %	0.894	0.157	0.116	Léger overfitting
XGBoost	93.1 %	0.796	0.964	97.7 %	14.8 %	0.988	0.201	0.053	Overfitting sévère
Random Forest	93.4 %	0.776	0.966	98.3 %	10.1 %	0.993	0.224	0.053	Overfitting sévère
KNN (k=5)	86.8 %	0.637	0.928	90.2 %	28.9 %	0.976	0.358	0.103	Overfitting sévère

Figure 12 — Comparaison des 6 modèles de Machine Learning (encodage corrigé, SMOTE sur le train uniquement)




Figure 12 — Comparaison des six modèles — (a) pouvoir discriminant (AUC test vs AUC CV-5) ; (b) écart de surapprentissage

4.4.3 Analyse du surapprentissage et courbes d'apprentissage

L'écart AUC train/test révèle des comportements très contrastés. La régression logistique présente un écart quasi nul (≈ 0) — excellente généralisation —, tandis que le KNN (gap = 0,358), le Random Forest (0,224) et XGBoost (0,201) sur-apprennent sévèrement : ils mémorisent les données d'entraînement plutôt que d'apprendre des règles généralisables. Le SVM se situe en position intermédiaire (gap = 0,181). Les courbes d'apprentissage (Figures 13–14) confirment que tous les modèles convergent en validation croisée ; sur le jeu de test original (déséquilibré), seuls la régression logistique et le SVM conservent un AUC élevé.




Figure 13 — Courbes d'apprentissage des six modèles — AUC d'entraînement vs validation croisée selon la taille de l'échantillon




Figure 14 — Courbes d'apprentissage — focus sur le SVM retenu et la régression logistique de référence (zones vertes = convergence)

4.4.4 Stabilité et calibration

La stabilité inter-folds (Figure 15) montre une faible dispersion de l'AUC, gage de robustesse. L'analyse de calibration (Figure 16) et le score de Brier établissent que le SVM (Brier = 0,074), comme les modèles d'ensemble, est bien calibré, alors que la régression logistique, malgré son excellente discrimination, est moins bien calibrée (Brier = 0,162) sur le jeu de test déséquilibré.




Figure 15 — Stabilité de l'AUC par fold de validation croisée pour les six modèles




Figure 16 — Courbes de calibration (fiabilité) des six modèles — le SVM et les modèles d'ensemble sont bien calibrés

Fig B3 — Matrices de confusion des 6 modèles ML
(données de test, n=2706 — SMOTE appliqué sur le train uniquement)




Figure 17 — Matrices de confusion des six modèles (jeu de test, n = 2 706) — le SVM retenu (VN = 67, FP = 82, FN = 145, VP = 2 412) offre la meilleure spécificité parmi les modèles à forte sensibilité

4.4.5 Sélection et justification du meilleur modèle

La sélection repose sur trois critères simultanés : (1) un pouvoir discriminant élevé (AUC CV-5 et AUC test) ; (2) une bonne calibration (score de Brier faible) ; (3) une spécificité acceptable malgré le déséquilibre. Le SVM calibré (noyau RBF) est retenu comme meilleur modèle de prédiction : il combine le meilleur AUC en validation croisée (0,969), un AUC test élevé (0,795), une excellente calibration (Brier = 0,074) et la meilleure spécificité (45,0 %) parmi les modèles à forte sensibilité — un atout décisif dans un problème aussi déséquilibré. La régression logistique demeure la référence interprétable la plus généralisable (AUC test = 0,820 ; gap $\approx$ 0) et est conservée pour l'analyse explicative. Le SVM est déployé dans l'application HEARTH (Section VII).

Tableau 9 — Synthèse de la validation complète des six modèles

Modèle	AUC test	AUC CV-5	Gap	Brier	Calibration	Diagnostic
Rég. Logistique	0,820	0,818	−0,001	0,162	Mauvaise	Bonne généralisation
SVM (RBF) ★	0,795	0,969	0,181	0,074	Bonne	Modèle retenu
Arbre Décision	0,744	0,894	0,157	0,116	Acceptable	Léger surapprentissage
XGBoost	0,796	0,988	0,201	0,053	Bonne	Surapprentissage sévère
Random	0,776	0,993	0,224	0,053	Bonne	Surapprentissage

Forest						sévère
KNN (k = 5)	0,637	0,976	0,358	0,103	Acceptable	Surapprentissage sévère

4.5 Interprétabilité des modèles — SHAP et importance par permutation

L'interprétabilité est abordée selon deux angles complémentaires. L'analyse SHAP, appliquée à la régression logistique comme modèle linéaire de référence, décompose la contribution de chaque variable à la prédiction. Elle confirme la prééminence écrasante de l'âge (importance moyenne = 1,16), suivi du statut de femme mariée (0,31), du nombre d'enfants vivants (0,30) et du milieu de résidence (0,27). L'importance par permutation, calculée sur le SVM retenu, corrobore cette hiérarchie : la permutation de l'âge entraîne à elle seule une chute d'AUC de 0,327, très loin devant les autres variables.




Figure 18 — Importance globale des variables (valeurs SHAP, régression logistique) — l'âge domine très largement

Fig F2 — SHAP Beeswarm : distribution des contributions par variable
Rouge = valeur élevée · Bleu = valeur faible · Axe X = impact sur la prédiction



Figure 19 — Diagramme SHAP en essaim — distribution et sens de l'effet de chaque variable sur la prédiction

Fig F3 — SHAP Waterfall : femme n°12 (prédiction correcte : Ne désire pas)
 Âge = 45 ans · Nb enfants vivants = 7




Figure 20 — Décomposition SHAP individuelle (waterfall) — explication de la prédiction pour une femme du jeu de test




Figure 21 — Importance par permutation pour le SVM retenu — chute d'AUC lorsque chaque variable est permutée

V. Discussion

5.1 Principaux enseignements

Les résultats révèlent une dynamique de fécondité remarquable : 94,5 % des femmes déclarent désirer un autre enfant, très au-dessus des 64,95 % africains (Ahinkorah et al., 2020). Seuls l'âge (OR = 0,859 ; H1 validée) et, après ajustement, le milieu rural (OR = 0,703 ; H5 infirmée car de sens opposé à l'hypothèse) réduisent significativement ce désir. Les résultats contre-intuitifs pour H2, H3 et H4 s'expliquent par la saturation de la classe majoritaire : lorsque 94,5 % des femmes désirent un enfant, les variables distinguent davantage des sous-profils au sein des désirantes que les désirantes des non-désirantes.

5.2 Apport du Machine Learning et de SMOTE

SMOTE a considérablement amélioré la spécificité des modèles : de 3,1 % pour la régression logistique brute (sans rééquilibrage) à 45,0 % pour le SVM avec SMOTE, et jusqu'à 76,5 % pour la régression logistique pondérée. L'analyse du surapprentissage montre que les modèles à forte capacité (Random Forest, XGBoost, KNN) sur-apprennent sévèrement, tandis que le SVM offre

le meilleur compromis entre discrimination, calibration et spécificité. La confrontation systématique de six algorithmes, rarement réalisée sur ce thème, constitue un apport méthodologique central de ce travail.

5.3 Contribution originale

Ce travail apporte quatre contributions : (i) la première analyse dédiée au Cameroun de la variable v602 à partir des données EDSC-V 2018 ; (ii) la première application combinant régression logistique et Machine Learning multi-algorithmes avec SMOTE sur ce thème au Cameroun ; (iii) un encodage DHS rigoureux (contraception, statut matrimonial et religion éclatés en indicatrices) corrigeant les approximations des analyses antérieures ; (iv) la mise en évidence d'une prévalence de 94,5 %, très supérieure aux moyennes africaines, et son opérationnalisation dans une application web.

5.4 Limites

- Déséquilibre des classes (94,5 % vs 5,5 %) : même après SMOTE, la spécificité reste perfectible hors du SVM et de la régression logistique pondérée.
- Multicolinéarité élevée : l'âge (VIF = 19,43) et le quintile de richesse (VIF = 11,98) dépassent le seuil critique de 10.
- Nature transversale des données : les Odds Ratios mesurent des associations, non des causalités.
- Biais de désirabilité sociale : v602 capture des intentions déclarées et non des comportements reproductifs effectifs.
- Absence des variables relatives au partenaire masculin, déterminant pourtant reconnu du désir de fécondité.

VI. Conclusion et recommandations

6.1 Synthèse

Cette étude a analysé les déterminants du désir d'avoir un autre enfant au Cameroun (EDSC-V 2018, $n = 13\,527$ femmes) en combinant régression logistique binaire sur 19 variables et Machine Learning avec traitement du déséquilibre par SMOTE. La prévalence du désir est de 94,5 %. L'âge ($OR = 0,859$) et le milieu de résidence sont les facteurs les plus structurants. Parmi les six modèles comparés, le SVM calibré (noyau RBF) est retenu ($AUC\ CV-5 = 0,969$; $AUC\ test = 0,795$; $Brier = 0,074$; spécificité = 45,0 %), la régression logistique demeurant la référence interprétable la plus généralisable ($AUC\ test = 0,820$).

6.2 Recommandations

- Renforcer l'accès à l'éducation et à l'emploi des femmes, en particulier dans les régions septentrionales, pour favoriser le recul de l'âge au premier enfant ;
- Améliorer l'accessibilité des services de planification familiale, en ciblant prioritairement les femmes de 15–24 ans (désir le plus élevé : jusqu'à 98,4 %) ;
- Promouvoir des programmes de sensibilisation à l'espacement des naissances adaptés au contexte culturel camerounais ;

- Intégrer la dimension masculine dans les politiques de santé reproductive.

6.3 Perspectives

- Explorer des techniques de coût asymétrique pour améliorer encore la spécificité ;
- Adopter un modèle logistique multiniveau tenant compte de la structure régionale ;
- Analyser séparément les sous-groupes par parité ou tranche d'âge pour contourner la multicollinéarité ;
- Comparer les résultats avec les vagues précédentes de l'EDSC (1991–2018) pour saisir la dynamique temporelle.

VII. Application HEARTH

7.1 Présentation

HEARTH est une application web responsive permettant d'estimer la probabilité qu'une femme camerounaise de 15 à 49 ans désire avoir un enfant supplémentaire, à partir du modèle SVM calibré (noyau RBF) entraîné sur les données EDSC-V 2018 (n = 13 527 femmes, 19 variables).

Application : <https://hearth-edsc-prediction-d-avoir-des.onrender.com>

Code source : <https://github.com/Kayela2/Prediction-d-avoir-des-enfants/tree/main/EDS-Cameroon>

7.2 Fonctionnement

L'utilisateur crée un compte, renseigne un profil en plusieurs étapes (âge, situation familiale, niveau d'instruction, milieu de résidence, quintile de richesse, etc.) et obtient une probabilité personnalisée accompagnée des facteurs explicatifs les plus influents. Stack technique : React + TypeScript + TailwindCSS (frontend) · FastAPI + Python + scikit-learn (backend) · déploiement sur Render.

Références bibliographiques

- Ahinkorah, B. O., Ameyaw, E. K., Hagan Junior, J. E., Seidu, A.-A., & Budu, E. (2020). Drivers of desire for more children among childbearing women in sub-Saharan Africa. *BMC Pregnancy and Childbirth*, 20(1), 775.
- Bongaarts, J. (1978). A framework for analyzing the proximate determinants of fertility. *Population and Development Review*, 4(1), 105–132.
- Bongaarts, J., & Casterline, J. (2012). Fertility transition: Is sub-Saharan Africa different? *Population and Development Review*, 38(Suppl. 1), 153–168.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.

- Church, A. C., Ibitoye, M., Chettri, S., et al. (2023). Traditional supports and contemporary disrupters of high fertility desires in sub-Saharan Africa. *Reproductive Health*, 20(1), 86.
- Frontiers in Digital Health. (2024). Exploring machine learning algorithms for predicting fertility preferences among reproductive age women in Nigeria. <https://doi.org/10.3389/fdgth.2024.1495382>
- Hosmer, D. W., & Lemeshow, S. (2000). *Applied Logistic Regression* (2e éd.). John Wiley & Sons.
- Institut National de la Statistique du Cameroun (INS) & ICF. (2020). *Enquête Démographique et de Santé du Cameroun 2018 (EDSC-V)*. Yaoundé, Cameroun & Rockville, Maryland, USA.
- Johnson-Hanks, J. (2003). Éducation, ethnicité et pratiques reproductives au Cameroun. *Population*, 58(2), 171–200.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- Mboup, G., & Saha, T. (1995). *Fertility*. DHS Comparative Studies No. 18. Calverton, Maryland: Macro International Inc.
- Muluneh, M. W., & Moyehodie, Y. A. (2021). Determinants of desire for more children among women in Ethiopia. *BMC Women's Health*, 21(1), 408.
- Seidu, A.-A., et al. (2025). What factors influence fertility and the desire for more children in Ghana? *SAGE Open Medicine*. <https://doi.org/10.1177/20503121251347756>
- Westoff, C. F., & Bankole, A. (2000). Reproductive preferences in developing countries at the turn of the millennium. *DHS Comparative Reports*, 2. ORC Macro.

Annexe 1 — Vérification de la multicolinéarité (VIF)

Le tableau ci-dessous présente les valeurs complètes du VIF pour les variables du modèle corrigé. L'âge (VIF = 19,43) et le quintile de richesse (VIF = 11,98) dépassent le seuil critique de 10, signalant une multicolinéarité à surveiller. Celle-ci n'affecte pas la qualité prédictive du SVM retenu mais limite l'interprétation des effets propres de ces variables.

Tableau 10 — Facteur d'inflation de la variance (VIF) — modèle corrigé · EDSC-V Cameroun 2018

Variable	VIF	Diagnostic
Âge	19.43	PROBLÈME
Quintile de richesse	11.97	PROBLÈME
Niveau d'instruction	7.10	Modéré
Nb enfants vivants	4.55	OK
Mariée (vs jamais mariée)	3.81	OK
Emploi (travail)	3.06	OK
Résidence rurale (vs urbaine)	2.24	OK
Musulmane (vs Catholique)	1.81	OK
Protestante (vs Catholique)	1.70	OK

Union libre (vs jamais mariée)	1.67	OK
Nb enfants décédés	1.36	OK
Région septentrionale	1.32	OK
Contraceptif moderne	1.29	OK
Veuve (vs jamais mariée)	1.29	OK
Séparée (vs jamais mariée)	1.26	OK
Autres chrétiennes (vs Catholique)	1.20	OK
Divorcée (vs jamais mariée)	1.12	OK
Contraceptif traditionnel	1.07	OK
Autres religions (vs Catholique)	1.05	OK